

Beispiel Vergleich Mittelwerte

April 26, 2016

1 Übung: Differenz von Mittelwerten

Berechnen Sie zwei Mittelwerte \bar{x}_1 und \bar{x}_2 über zwei Zeiträume und deren Differenz $\Delta x = \bar{x}_2 - \bar{x}_1$. Wie wahrscheinlich ist es, dass die Differenz nicht rein zufällig ist? Beschreiben Sie die Signifikanz der Änderung. Nutzen Sie eine Monte-Carlo-Methode zur Berechnung der Signifikanz (z.B. durch zufälliges Umsortieren der Zeitreihe).

```
In [8]: %pylab inline
        # X Zeitreihe September-Eisausdehnung von 1972-1992 aus Satellitendaten. Einheit: Millionen Qua
X=array([7.3,7.7,7.5,7.3,7.3,7.2,7.9,7.2,7.9,7.3,7.5,7.5,7.2,6.9,7.5,7.5,7.5,7.0,6.2,6.6,7.6])
print('Durchschnitt der ersten 10 Jahre:',(mean(X[0:10])))
print('Durchschnitt der letzten 10 Jahre:',(mean(X[11:21])))
Differenz=mean(X[0:10])-mean(X[11:21])
print('Differenz:',Differenz)
```

```
Populating the interactive namespace from numpy and matplotlib
Durchschnitt der ersten 10 Jahre: 7.46
Durchschnitt der letzten 10 Jahre: 7.15
Differenz: 0.31
```

```
In [9]: N=10000
        D=[]
        for i in range(0,N):
            shuffle(X)
            D.append(mean(X[0:10])- mean(X[11:21])) #Differenz
        D=array(D)
        A=sum(D>=Differenz)
        P=A*100./N #Irrtumswahrscheinlichkeit in %
        S=100.-P #Signifikanz in %
        print('Anzahl:', A, 'von ',N)
        print('Irrtumswahrscheinlichkeit',P, '%')
        print('Signifikanz',S, '%')
```

```
Anzahl: 395 von 10000
Irrtumswahrscheinlichkeit 3.95 %
Signifikanz 96.05 %
```

2 Prüfverfahren: Vergleich zweier Mittelwerte

Siehe Schönwiese, Abschnitt 8.2.1 (Seite 124, 4. Auflage)

Gleicher Stichprobenumfang $n = n_a = n_b$:

$$\hat{t} = \frac{|\bar{a} - \bar{b}| \sqrt{n}}{\sqrt{s_a^2 + s_b^2}}$$

Mit Freiheitsgrad $\Phi = 2n - 2$

```
In [10]: import scipy.stats as st
         t_test=st.t.cdf # Student t
         z_test=st.norm.cdf # Normalverteilung

         n=10
         X=array([7.3,7.7,7.5,7.3,7.3,7.2,7.9,7.2,7.9,7.3,7.5,7.5,7.2,6.9,7.5,7.5,7.5,7.0,6.2,6.6,7.6])
         a=mean(X[0:10])
         b=mean(X[11:21])
         sa=std(X[0:10],ddof=1)
         sb=std(X[11:21],ddof=1)

         phi=2*n-2
         t=(a-b)*sqrt(n)/(sqrt(sa**2+sb**2))
         print(t,phi)
```

1.80014986263 18

```
In [13]: a,sa
```

```
Out[13]: (7.4600000000000009, 0.27568097504180455)
```

```
In [14]: b,sb
```

```
Out[14]: (7.1500000000000004, 0.46963342678684566)
```

```
In [24]: t_test(t,phi)
```

```
Out[24]: 0.95569007258302929
```

```
In [25]: z_test(t)
```

```
Out[25]: 0.96408151096942074
```

Signifikanz 95.6% (t-Test) bzw. 96.4% (Normalverteilung) für Ablehnung der Nullhypothese.
Die Untersuchung zeigt: die Mittelwerte sind verschieden mit einem Signifikanzniveau von >95%.

2.1 Octave

```
In [8]: n=10;
         X=[7.3,7.7,7.5,7.3,7.3,7.2,7.9,7.2,7.9,7.3,7.5,7.5,7.2,6.9,7.5,7.5,7.5,7.0,6.2,6.6,7.6];
         a=mean(X(1:10));
         b=mean(X(12:21));
         sa=std(X(1:10));
         sb=std(X(12:21));

         phi=2*n-2;
         t=(a-b)*sqrt(n)/(sqrt(sa**2+sb**2));
         disp(num2str(t));
         disp(num2str(phi));
```

```
Out[8]: 1.8001
        18
```

```
In [10]: tcdf(t,phi)
```

```
Out[10]: ans = 0.95569
```

```
In [13]: tcdf(t,10000)
```

```
Out[13]: ans = 0.96407
```

Die kumulative Verteilungsfunktion der t-Verteilung wird genutzt, um die Quantile zu berechnen. Im Grenzfall für große Freiheitsgrade/Anzahl von Stichproben entspricht das Ergebnis dem der Normalverteilung.